

TÜRKİYE CUMHURİYETİ
YILDIZ TEKNİK ÜNİVERSİTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



DERİN ÖĞRENME İLE UYDU GÖRÜNTÜLERİNDEN
BULUT OLAN BÖLGE TESPİTİ

20011003 – Muhammed İsa GÜL
20011627 – Hakan ADİYAMAN

BİLGİSAYAR PROJESİ

Danışman
Prof. Mine Elif KARSLIGİL

Aralık, 2023

TEŞEKKÜR

"Derin Öğrenme ile Uydu Görüntülerinden Bulut Olan Bölge Tespiti" adlı projemizde görsel verileri kullanarak bulutların tespit edilmesi amacını taşımaktadır. Yapmış olduğumuz proje bir çok sektörün operasyonel faaliyetlerinde etkili bir şekilde kullanılmasını sağlamaktadır

Başta sevgili hocamız M.Elif KARSLIGİL'in bizi önce teknik bilgisi ve uzmanl ığıyla daha sonra da liderliğiyle projemizin başarıyla gerçekleşmesinde büyük rol oynamıştır. Yaptığımız her hatayı titizlikle inceleyip verdiği çözümlerle bize ışık tutmuştur. Kendisine güler yüzlülüğü anlayışlılığı ve bilgisiyle bizi aydınlatmasından ötürü şükranlarımızı sunuyoruz.

Aynı zamanda gerçek bir profesyonel iş yaşamı deneyimi sunan bu projenin tamamlanmasında takım arkadaşlığı uyumunun önemini bizzat yaşayarak deneyimledik. İşbirliği başarı için olmazsa olmazlardan olduğunu görmüş olduk.

Muhammed İsa GÜL
Hakan ADİYAMAN

İÇİNDEKİLER

KISALTMA LİSTESİ	v
ŞEKİL LİSTESİ	vi
TABLO LİSTESİ	vii
ÖZET	viii
ABSTRACT	ix
1 Giriş	1
2 Ön İnceleme	2
3 Sistem Analizi	4
4 Fizibilite	5
4.1 Teknik Fizibilite	5
4.1.1 Yazılım Fizibilitesi	5
4.1.2 Donanım Fizibilitesi	6
4.1.3 İş Gücü ve Zaman Planlaması	6
4.2 Ekonomik Fizibilite	6
4.3 Yasal Fizibilite	7
5 Sistem Tasarımı	8
5.1 Veri Seti	8
5.2 U-Net ile Bulut Olan Bölge Tespiti	10
6 Deneysel Çalışmalar	12
7 Performans Analizi	17
8 Sonuç	18
Referanslar	19

KISALTMA LİSTESİ

CNN	Convolutional Neural Network
DANN	Domain-Adversarial Neural Network
GB	Gigabyte
GPU	Graphics Processing Unit
kB	Kilobyte
NIR	Near Infrared
RAM	Random Access Memory
RGB	Red Green Blue
SWIR	Short Wave Infrared
NASA	National Aeronautics and Space Administration
IoU	Intersection over Union

ŞEKİL LİSTESİ

Şekil 4.1	Proje Gantt Diyagramı	6
Şekil 5.1	Landsat 8 uydu görüntüsü	9
Şekil 5.2	Parçalanmış uydu görüntüleri	10
Şekil 5.3	U-Net mimarisi	11
Şekil 6.1	Büyük ve küçük batch değeri ve hata oranları	13
Şekil 6.2	Kısmen iyi olan test sonuçları	14
Şekil 6.3	Kısmen kötü olan test sonuçları	15
Şekil 6.4	Döngü sayısı ve doğruluk oranı ilişkisi	16
Şekil 7.1	Sistem kullanımı	17

TABLO LİSTESİ

Tablo 4.1	Google Colab'ın sunduğu hizmetler ve özellikleri	6
Tablo 4.2	Toplam harcamalar	7
Tablo 6.1	Eğitim sonuçları	16

DERİN ÖĞRENME İLE UYDU GÖRÜNTÜLERİNDEN BULUT OLAN BÖLGE TESPİTİ

Muhammed İsa GÜL

Hakan ADİYAMAN

Bilgisayar Mühendisliği Bölümü

Bilgisayar Projesi

Danışman: Prof. Mine Elif KARSLIGİL

Derin öğrenme modelleri kullanarak uydu görüntülerinden bulut olan bölge tespiti işlemi oldukça yagındır. Bu çalışmada ise, daha çok biyomedikal görüntülerin işlenmesinde kullanılan U-Net mimarisinin uydu görüntülerinden bulut tespiti konusuna uyarlanması ele alınmıştır. Landsat 8 uydusuna ait olan uydu görüntülerinin erişilebilirlik ve çeşitlilik özellikleri sebebiyle kullanılmasına karar verilmiştir. Tasarlanan U-Net mimarili derin öğrenme modeli ile geleneksel yöntemlerin oldukça önüne geçmiştir. "intersection over union", "loss", "accuracy" gibi değerlendirme metrikleri kullanılarak modelin kalitesi değerlendirilmiştir. Hiper parametre değerlerine bağlı olarak değişen eğitim sonuçlarında doğruluk oranının 0.97'lere ulaştığı, intersection over union değerinin ise 0.96'lara ulaştığı gözlenmiştir.

Anahtar Kelimeler: Derin öğrenme, U-Net, uydu, bulut tespiti, sinir ağıları, görüntü işleme.

CLOUD DETECTION FROM SATELLITE IMAGES WITH DEEP LEARNING

Muhammed İsa GÜL
Hakan ADIYAMAN

Department of Computer Engineering
Computer Project

Advisor: Prof. Mine Elif KARSLIGİL

The process of region testing, which is a cloud from satellite images using deep learning models, is quite common. On the other hand in this report, discussed by adapting the U-Net architecture which is mostly used for biomedical images, from satellite images to cloud environment. It was decided to operate the accessibility and feature features of the satellite image belonging to the Landsat 8 satellite. With the designed U-Net architecture deep learning model, it has far surpassed traditional methods. Evaluation metrics such as "intersection over union", "loss", "accuracy" were evaluated by using the quality of the model. Depending on the hyper parameter values, the accuracy values in the training results reached 0.97, and the value of intersection over union reached 0.96.

Keywords: Deep learning, U-Net, satellite, cloud detection, neural networks, image processing.

1

Giriş

Uydu görüntüleri doğal afetlerde zarar tespiti başta olmak üzere pek çok alanda kullanılmaktadır. Özellikle NASA'nın Landsat ve ESA'nın Copernicus programı ile uydulardan çekilmiş görüntüleri herkese açık bir şekilde paylaşmasıyla uydu görüntüleri kullanılarak yapılan çalışmaların sayısı oldukça arttı.

Türkiye gibi deprem açısından riskli olan bölgelerde uydu görüntülerinin doğruluğu büyük önem taşımaktadır. Deprem sonrası hasarlı bölgelerin tespiti ve ekiplerin o bölgelere yönlendirilmesi için bölgenin uydu görüntülerine ihtiyaç duyulmaktadır. Ancak bölgedeki bulutlar görüntü alınabilmesini zorlaştırmaktadır.

Uydu görüntüleri, bulutlu alanların tespiti için kullanılan en yaygın ve güvenilir kaynaklardan biridir. Uydu görüntülerindeki bulutlu alanları tespit etmek, manuel olarak oldukça zaman alıcıdır ve insan hatasına neden olabilir. Bu nedenle, otomatik bulut tespit sistemleri geliştirilmektedir. Bu sistemler, uydu görüntülerini analiz ederek bulutlu alanları tespit eder ve ekipler bilgilendirilir. Bu projede, uydu görüntülerinden bulutlu bölgelerin tespiti için bir algoritma geliştirilmiştir. Bu algoritma, derin öğrenme modelleri kullanarak bulutlu alanları belirler. Unet mimarisine dayanan bir derin öğrenme modeli olan RS-Net kullanılacaktır. Böylece bulut tespit edilen uydu görüntüsünden istenilen bilgilerin alınamayacağına karar verilir ve bölgeden tekrar görüntü alınmasına karar verilir. Zaman ve emek israfının önüne geçilmiş olur.

Geliştirilen otomatik bulut tespit sistemi, manuel tespit yöntemlerine göre daha hızlı ve doğru sonuçlar sağlar. Ayrıca, sistemin doğru çalışması için insan müdahalesine gerek yoktur. Projenin sonucu olarak, geliştirilen algoritma, uydu görüntüleri kullanarak bulutlu alanların tespit edilmesinde son derece başarılı olmuştur. Uydu görüntüleri, geniş bir coğrafi alanı kapsayabilir ve bu nedenle, doğru bir şekilde analiz edildiklerinde birçok alanda faydalar sağlayabilir. Bu proje, doğal afetler, çevre koruma, tarımsal üretim, ulaşım ve askeri faaliyetler gibi birçok alanda uydu görüntüleri kullanılarak yapılan çalışmaların önemini vurgulamaktadır.

2 Ön İnceleme

Litaratür taraması yapılarak uydu görüntülerinden bulut olan bölge tespitinde kullanılan yaygın yöntemler tespit edilmiştir. Bu yöntemler doğruluki kullanılan veri seti, erişilebilirlik, kullanım kolaylığı gibi çeşitli özellikler bakımında değerlendirilmiştir.

İncelenen bir çalışmada [1] CNN tabanlı bulut tespiti yapılmıştır. World-View-2 ve Sentinel-2 uydularına ait olan görsellerin kullanıldığı bu çalışmada doğruluk oranının 0.89 olduğundan bahsedilmiştir. Bu çalışmada daha çok Güney Pasifik Okyanusu'ndaki Fiji Adaları üzerine yoğunlaşmıştır. Bu tarz bölgelerde okyanus ile bulutların birbirine karıştırılması oldukça yaygındır. Çalışmayı gerçekleştiren araştırmacılar çok kanallı olan görselleri tek kanala indirgeyerek istenilen özellik vektörü çıkarmayı amaçlamıştır. Sonuçları ise genel doğruluk yöntemi olan doğru tahmin sayısının toplam piksel sayısına bölünmesi ile elde ettikleri değer ve kritik başarı indeksi denilen isabet sayısının ıskalama oranına bölünmesiyle elde edilen değerler ile ölçmüşlerdir.

İncelenen çalışmalardan bir diğerinde [2]ise eşik yöntemidir. Bu yöntemde belli bir renk eşiği kullanılmak ya da bölgenin bulutsuz bir görüntüsüyle yeni görüntünün karşılaştırılması gibi bazı temel teknikler kullanılmaktadır. Ancak bu teknikler ile kar, gölet, çöl gibi bölgeler bulut olarak değerlendirilebilmektedir. Landsat 8 uydusuna ait olan görsellerin kullanıldığı bu çalışmada ise doğruluk orarnın oldukça düşük olduğu farkedilmiştir. Yaklaşık 0.54 değerine sahip olan doğruluk oranı yöntemin kolaylığına göre kabul edilebilir bir değerdir.

Yaygın olarak kullanılan derin öğrenme modelleri dışında süperpiksel algoritmalarının bu konu kapsamın kullanıldığı projeler bulunmaktadır. SLIC algoritması kaliteli süper pikselleri hesaplamak için kullanılan yaygın yöntemlerden biridir. Bu yöntemi kullanan çalışma [3] incelendiğinde 93% gibi bir tahmin doğruluğuna ulaştıkları görülmüştür. Veriseti olarak GF-1 uydusuyla çekilmiş görüntüler kullanılmıştır. Sistem olarak TITAN X GPU, 128 GB bellek ve bir Intel Xeon E5-2670 CPU (2,30 GHz)

kullanıldığı görülmüştür.

Ön inceleme aşamasında MOSSO [4] tabanlı bir kümele tekniği dikkat çekmiştir.

Temel kümeleme tekniklerinin optimal çözümde takıldığı görülmektedir. Bunu azaltmak için, verimli kümeleme tekniği olarak optimizasyon yaklaşımının, yüksek kümeleme doğruluğu elde etmek için daha kolay bir yaklaşım olduğu tespit edilmiştir. Bu, bulutları en az eğitim örneği ve hesaplama karmaşıklığı ile ayırt etmek için en uygun çözüme ulaşmada yardımcı olabilecek meta-sezgisel optimizasyon algoritmasının geliştirilmesine olanak sağladı. Verimli kümeleme tekniği olarak optimizasyon yaklaşımının, yüksek kümeleme doğruluğu elde etmek için daha kolay bir yaklaşım olduğu bulunmuştu. MOSSO-C, doğrudan ham piksel değerleri üzerinde çalışır ve bu nedenle önceden bulunmuş özellikleri elde etmek için insan müdahalesi gerektirmez. Algoritmanın bir diğer önemli özelliği de bir hedef vektör tasarlamasıdır. Landsat 8 uydusuna ait görüntülerin kullanıldığı bu çalışmada %96 doğruluk oranına ulaşıldığı belirtilmiştir.

3

Sistem Analizi

Derin öğrenme modeli için kullanılacak görseller Landsat 8 uydusundan çekilmiş ve halka açık olarak paylaşılan veri setinden elde edilen daha küçük parçalardan seçilmiştir. Bu parçaların her biri 384x384 ölçütünde ve yaklaşık 300 kB boyuntundadır. Ayrıca her görselin mavi, kırmızı, yeşil gibi çeşitli dalga boylarındaki durumları veri setinde ayrı olarak paylaşılmıştır. Bu görsellerden bulut olan bölge tespiti için eşik değer belirleme gibi klasik yöntemlerle istenilen doğrulukta sonuçlar elde edilememektedir. Bu sebeple oldukça yaygın ve sonuçları bakımında iyi olan derin öğrenme tabanlı bir yaklaşım izlenilmesine karar verilmiştir.

Model için toplam bin adet görsel kullanılmasına karar verilmiştir. Bunların 700 tanesi "train" yani eğitimde kalan 300 adet ise "test" yani eğitim sonuçlarının doğruluğunu hesaplamak kullanılmasına karar verilmiştir. İstenile doğruluk değerine ulaşamaması durumunda görsel sayısının artırılabilceğine karar verilmiştir.

Derin öğrenme modeli için araştırmalar yapıldığında U-Net mimarisinin kullanılmasına karar verilmiştir. U-Net özellikle medikal görüntüleme uygulamalarında sıkça kullanılan bir CNN mimarisidir. U-Net diğer CNN mimarilerinden farklı olarak hrm evrişimli hem de de-convolutional katmanlar içermesiyle daha iyi segmentasyon sonuçları verir.

Geliştirilen algoritmanın test edilmesinde manual olarak maskelenemiş bulut görselleri ile algoritma sonucu oluşan maskeler karşılaştırılarak benzerlik oranının kullanılmasına karar verilmiştir. Ayrıca sistem olarak eğitim hızının da göz önünde bulundurulmasına karar verilmiştir. Eğitim sonuçlarının karşılaştırılmasında "accuracy", "loss" ve "intersection over union" gibi değerlerin göz önünde bulundurulması gerektiği düşünülmüştür.

4 Fizibilite

Uydu görüntülerinden bulut olan bölge tespitinde bir çok yöntem kullanılmaktadır. Bu proje kapsamında farklı yöntemler incelenmiş ve karşılaştırmalar yapılmıştır. Ayrıca projede kullanılmak üzere veri seti araması yapılmıştır. Erişilebilirlik ve kalite bakımından değerlendirmeler yapıldıktan sonra Landsat uydusuna ait veri setinin kullanılmasına karar verilmiştir. Kodlanan model için uygun olan görüntü formatı, boyutu gibi konularda kolaylık sağlayan veri seti "kaggle" internet sitesinden temin edilmiştir.

Projenin gerçekleştirme süreçleri ve fizibilite çalışmaları teknik fizibilite, iş gücü ve zaman planlaması, ekonomik fizibilite, yasal fizibilite başlıklarında incelenmiştir.

4.1 Teknik Fizibilite

Projenin teknik fizibilite başlığı Yazılım ve Donanım olmak üzere iki alt başlığa ayrılmıştır.

4.1.1 Yazılım Fizibilitesi

Proje kapsamında kullanılabilecek yazılım dilleri ve yazılım araçları araştırılmıştır. Araştırmalara sonucunda C ve Python dillerinin öne çıktığı görülmüştür. Kullanım esnekliği ve kolaylık açısından Python dili tercih edilmiştir. Ayrıca Python diline bulunan NumPy, Pandas, Tensorflow, Keras gibi yazılım araçları kullanıcılara çok büyük kolaylıklar sağlamaktadır. Proje kapsamında Google'ın belli kısıtlar ile ücretsiz sunduğu Colab hizmeti kullanılmıştır. Colab veya diğer adıyla "Colaboratory", tarayıcınızda Python'u yazmanızı ve çalıştırmanızı sağlar. Hiç yapılandırma gerektirmez. GPU'lara ücretsiz erişim ve projelere kolay paylaşım imkanı sunar. Alternatif olarak yine Google Colab'ın kullanıcılara sunduğu Colab Pro hizmeti ile daha yüksek sistem özelliklerine sahip ortamlar kullanılabilir.

4.1.2 Donanım Fizibilitesi

Proje kapsamında Google Colab hizmetinin ücretsiz olarak sunduğu Nvidia Tesla K80 ekran kartı ve 16 GB RAM olan sistem tercih edilmiştir. Yine Google Colab' in sunduğu ancak ücretli olan Pro ve Pro+ hizmetleri bulunmaktadır. Bu hizmetlerin özellikleri Tablo 4.1'de gösterilmiştir.


Tablo 4.1 Google Colab'ın sunduğu hizmetler ve özellikleri

	Colab	Colab Pro	Colab Pro+
GPU	K80	K80, T4, T100	K80, T4, T100
RAM	16 GB	32 GB	52 GB
Süre Limiti	12 saat	24 saat	24 saat
Arka Planda Çalıştırma	Hayır	Hayır	Evet
Ücret	Ücretsiz	\$9.99/ay	\$49.99/ay

Colab hizmeti eğitim süreçleri için kullanılmıştır. Görsellerin incelenmesi, sonuçların değerlendirilmesi için kişi başı 1 bilgisayar olmak üzere toplam 2 bilgisayara ihtiyaç duyulmuştur. Önerilen sistem gereksinimleri 8 GB RAM, Nvidia GeForce GTX 1660 ekran kartı, 4 çekirdekli işlemci şeklindedir. Kullanılan sistemlerden ilki Acer A-515 16 GB RAM, Nvidia GeForce GTX 1650 ekran kartı, Intel i5 işlemci özelliklerine sahip laptop ikincisi ise Monster Abra v17.2 16 GB RAM, Nvidia RTX 3050 ekran kartı, Intel i7 işlemci özelliklerine sahip bir laptoptur.

4.1.3 İş Gücü ve Zaman Planlaması

Proje için danışman ile görüşme ile başlayan ve makale yazmaya kadar olan süreç Şekil 4.1'de Gantt diyagramı ile gösterilmiştir.



Şekil 4.1 Proje Gantt Diyagramı

4.2 Ekonomik Fizibilite

Proje için gerekli olan donanım sistemleri Google Colab ile ücretsiz olarak temin edilmiştir. Daha hızlı ve limitsiz olarak eğitim yapabilmek için aylık \$49.99 olan Colab

Pro+ tavsiye edilmektedir. Yazılım sistemleri için herhangi bir ücret ödenmemiştir. Kullanılan programlama dilleri ve kütüphaneleri ücretsiz olarak sunulmaktadır. Personel giderleri için adam-ay değeri kullanılmıştır. Projeyi 2 kişi yürütmüştür ve 0.25 adam/ay değerinde çalışılmıştır. 2 aylık bir çalışma süresinde 1 adam-ay persoel ihtiyacı olduğu hesaplanmıştır. Aylık maaş 20.000 TL olarak hesaplandığında personel maliyetleri 20.000 TL olarak hesaplanmıştır. Proje kapsamında olması gereken harcamalar Tablo 4.2'de gösterilmiştir .

Tablo 4.2 Toplam harcamalar

Hizmet	Tutar
1. Laptop	20.000 TL
2. Laptop	20.000 TL
Colab Hizmeti	1.0000 TL
1. Çalışan Toplam Ücreti	10.000 TL
2. Çalışan Toplam Ücreti	10.0000 TL
Toplam	61.000 TL

4.3 Yasal Fizibilite

Proje konusunun yasallığı araştırıldığında herhangi bir sakınca olmadığı tespit edilmiştir. Proje kapsamında kullanılacak uydu görüntüler Landsat 8 uydusuna aittir ve hepsi halka açık olarak paylaşılmıştır. NASA, kendi sitesinde görsellerin kullanılmasında sakınca olmadığını belirtmiştir. Kullanılan Python yazılım dili ve bu yazılım diline ait olan Tensorflow, Keras, PyTorch gibi kütüphanelerin herhangi bir telif hakkı bulunmamaktadır.

5


Sistem Tasarımı

Sistem tasarımı veri setinin hazırlanması ve U-Net mimarisi olmak üzere iki alt başlık altında incelenmiştir.

5.1 Veri Seti


Proje kapsamında kullanılabilecek veri setleri araştırılmıştır. Bir çok uzay programı olduğu görülmüştür. Bu programlar uzaydan çekilmiş olan uydu görüntülerinin halka açık olarak paylaşarak yeni çalışma alanlarının kapısını açmıştır. Görüntü işleme başta olmak üzere paylaşılan görselleri bir takım işlemlerde geçirerek işe yarar bilgiler elde edilmesi amaçlanmıştır. Bu kapsamda doğal afetlerin sebep olduğu yıkım hakkında daha detaylı bilgi alma konusu gündeme gelmiştir. Uydu görüntülerinin bu konuda çok faydalı olacağı bilinmektedir. Ancak çok önemli bir sorun bulunmaktadır: bulutlar. Bulut olan uydu görüntülerinden bilgi elde edebilmek oldukça güçtür. Bu sebeple çeşitli görüntü işleme teknikleri kullanarak bulut olan uydu görüntüleriyle vakit kaybetmenin önüne geçilmek istenmiştir.

Landsat 8, SPARCS, GF-1 Satellite, Sentinel gibi uydulardan elde görüntüler incelediğinde çeşitlilik ve erişilebilirlik açısından Landsat 8 uydusuna ait olan görsellerin kullanılmasına karar verilmiştir. Ayrıca "kaggle" [5] sitesinde bulunan bir veri setinde Landsat 8 uydusuna ait olan görüntülerin belirli oranda parçalanarak görüntü işleme adımlarında kullanılmaya uygun hale getirildiği görülmüştür. Şekil 5.1'de Landsat 8 uydusuna ait örnek bir görüntü bulunmaktadır.



Şekil 5.1 Landsat 8 uydu görüntüsü

Şekil 5.1'in oldukça geniş bir alanın görüntüsü olduğu anlaşılmaktadır. Bu kadar geniş alanı kapsayan görüntülerin hem dosya boyutu fazla olmakta hem de modele koyulduğu zaman çok iyi sonuçlar alınamamaktadır. Bu sebeple görseller daha küçük boyutlara bölünerek eğitime sokulmalıdır. Şekil 5.2'de örnek görseller bulunmaktadır.




Şekil 5.2 Parçalanmış uydu görüntüleri

5.2 U-Net ile Bulut Olan Bölge Tespiti

Alınan uydu görüntülerinden bulut olan bölgelerin tespiti için derin öğrenme modeli tasarlanmıştır. CNN olarak biline evrişimli sinir ağları sınıflandırma problemlerinde sıklıkla kullanılmaktadır. CNN yapısının görseller üzerindeki kullanımı ise piksellerin sınıflandırılmasına dayanmaktadır. Bir CNN olan U-Net ise daha çok biyomedikal görüntülerde kullanılmaktadır. U-Net yapısında "encode" ve "decode" blokları bulunmaktadır. "encode" bloğu Şekil 5.3'ün ilk yarısını temsil etmektedir. Bu blokta yer alan konvolüsyon adımlarında sisteme girdi olarak verilen görsellerin kanal sayısının artırılması amaçlanmaktadır. Her adımda görselin boyutu da düşürülmektedir. Aslında bu süreç sınıflandırma işlemlerinde kullanılan klasik bir yöntemdir. U-Net mimarisi ise yapısında bulundurduğu "decode" bloğu ile diğer yöntemlerden ayrılmaktadır. "encode" bloğunda aşağı inildikçe "feature map" denilen özellik haritasının kalitesi artarken uzamsal bilgi azalmaktadır.

Şekil 5.3'ün ikinci yarısını ifade eden "decode" bloğunda "upsampling" yaparak bu azalan uzamsal bilginin geri kazanılması amaçlanmaktadır. Üst katmanlarda uzamsal bilgi daha fazlayken özellik haritasının kalitesi düşüktür. Bu noktada U-Net'i diğer CNN mimarilerinden ayıran diğer bir özellik devreye girmektedir: "skip connection". Her katmadanda bulunan "skip connection" ile aşağı inildikçe azan uzamsal bilgilerin daha efektif kullanılması sağlanmıştır. "concatenate" denilen birleştirme işlemi sayesinde yüksek kalitedeki özellik haritaları ile üst katmanlarda bulunan uzamsal

bilgilerin bir arada kullanılabilir. U-Net mimarisi




Şekil 5.3 U-Net mimarisi

6 Deneysel Çalışmalar

Uydu görüntülerinden bulut olan bölge tespiti konulu bu çalışmada U-Net mimarili derin öğrenme modelinin kullanıldığından bahsedilmiştir. Modelin kodlanması için Python programlama dili ve bu dile ait olan "tensorflow" ve "keras" kütüphaneleri kullanılmıştır. Görsellerin ve maskelerin modele uygun halde kullanılması için ise "opencv" kütüphanesinden yararlanılmıştır. Matris işlemleri için ise "numpy" kütüphanesi kullanılmıştır.

Derin öğrenme modellerinde eğitimi yönetmek için bazı dış parametreler kullanılmaktadır. Bu parametrelerin çeşitli değerleri kullanılarak en optimum model ele edilmeye çalışılmaktadır. Bu tarz parametrelere hiper parametre denilmektedir. Bu proje kapsamında kullanılan hiper parametreler ve tanımları aşağıda açıklanmıştır.


- **learning rate:** Derin öğrenme modellerinde parametreler güncellenmektedir. Bu güncellenme işlemi için öncelikle geri yayılım(backpropagation) adı verilen geriye doru türev olarak fark değeri bulunur. Bulunan fark değeri learning rate değeri ile çarpılır ve daha önce bulunmuş olan ağırlık değerlerinden çıkarılır. Böylece yeni ağırlık değeri hesaplanmış olur.
- **batch size:** Bu değer modelin aynı anda kaç farklı görsel işleyeceğini belirler. Evrimsel sinir ağları batch değerine karşı hassastır. Ufak değişikliklerin eğitim sonucuna etkisi çok olabilmektedir. Batch değeri arttıkça model grafiğinde dalgalanmalar olacaktır. Eğer eğitimde tüm görseller aynı anda kullanılmak istenirse süreç çok uzun sürecektir ve maliyet artacaktır. Bu sebeple modele en uygun batch değeri tespit edilmelidir. Görseller mini batch adı verilen gruplar halinde modele sokulmalıdır. Şekil 6.1’de yer alan ilk grafikte modele tüm görsellerin aynı verildiğinde oluşabilecek temsili bir grafik gösterilmiştir. 2. grafikte ise mini batch değeri kadar görselin modele verildiğinde oluşabilecek durum temsili olarak gösterilmiştir.



Şekil 6.1 Büyük ve küçük batch değeri ve hata oranları


- **epoch:** Eğitim tur sayısı olarak ifade edilebilecek olan epoch sayısı modelin kaç kere eğitim yapacağını belirtmektedir. İlk eğitim adımında doğruluk oranının düşük olması beklenmektedir. Eğitim ilerledikçe bu oranın arttığı görülmektedir.
- **early stop value:** Epoch aı verilen eğitim adımlarından bir noktadan sonra doğruluk oranının artmadığı görülebilmektedir. Bu noktada "early stop değeri" devreye girmektedir. Belirlenen değer kadar eğitim adımından sonra kontrol yapılır ve eğer doğruluk oranından istenilen artış elde edilmiyorsa eğitim erken durdurulur.
- **train count:** Modeli eğitmek için kullanılacak görsel sayısını ifade etmektedir.
- **valid count:** Her eğitim adımında sonra eğitim sonucunun doğruluk oranın kaç adet görsel üzerinden hesaplanacağını bu değer ile belirlenir.

Tablodaki sonuçlar incelendiğinde epoch sayısı ve eğitimde kullanılan görsel sayısı arttıkça test sonuçlarının iyileştiği tespit edilmiştir.



Şekil 6.2 Kismen iyi olan test sonuçları

Şekil 6.2’ diğer sonuçlara göre daha iyi olan örnekler gösterilmiştir. Ancak deniz, çöl, buzul gibi bulut ile karıştırılabilir bölgelerin üzerindeki bulutlar ile çok fazla bulut olan görsellerin tahmin sonuçlarının pek iyi olmadığı tespit edilmiştir. Bu durumlara örnek olan tahmin sonuçları ise Şekil 6.3’te gösterilmiştir.



Şekil 6.3 Kısımlen kötü olan test sonuçları


Belirlenen hiper parametreler çeşitli değerlerde kullanılarak modelin performansı test edilmiştir. Yapılan araştırmalar sonucunda learning rate değerinin 10^{-4} olarak

kullanılmasına karar verilmiştir. Tablo 6.1’de hiper parametrelerin çeşitli değerleri ile yapılan eğitim sonuçlarına ait sonuçlar gösterilmiştir.

Tablo 6.1 Eğitim sonuçları

Döngü	Örnek Sayısı	Eğitim Görsel Sayısı	Doğrulama Görsel Sayısı	Doğruluk	Kayıp	IOU	Geri Çağırma	F1 Skoru
10	2	1000	300	0.9278	0.1999	0.8514	0.8884	0.8924
20	2	1000	300	0.9582	0.1301	0.9111	0.9365	0.9379
30	2	1000	300	0.9667	0.1081	0.9283	0.9480	0.9504
20	4	1000	300	0.9482	0.1555	0.892	0.9156	0.9222
30	2	2000	600	0.9635	0.1062	0.9237	0.9416	0.9488


Eğitim sonuçları incelendiğinde döngü sayısı arttıkça doğruluk oranı ve diğer değerlendirme metriklerinin iyileştiği görülmektedir. Şekil 6.4’te 30 döngü süreli bir eğitimde döngü sayısı arttıkça doğruluk oranının nasıl değiştiği gösterilmiştir.



Şekil 6.4 Döngü sayısı ve doğruluk oranı ilişkisi

7 Performans Analizi

Projen sürecinde Google Colab hizmetinin ücretsiz versiynu kullanılmıştır. Eğitim sürecinde RAM, hafıza, ekran kartı kullanımı Şekil 7.1’de gösterilmiştir.



Şekil 7.1 Sistem kullanımı

8 Sonuç

Bu projede derin öğrenme modeli için U-Net mimarisi kullanılarak uydu görüntülerinden bulut olan bölge tespiti yapılmıştır. Önceki bölümlerde süreçten bahsedilmiştir. Kullanılan veri seti, eğitim sonuçları ve örnek görsellerle modelin test sonuçları ayrıntılarıyla anlatılmıştır. Özellikle deprem gibi doğal afetlerin yaşandığı durumlarda bu çalışmanın sonraki çalışmalara referans olması amaçlanmıştır.

U-Net modeli ile alınan sonuçlar incelediğinde modelin oldukça verimli olduğu sonucuna varılmıştır. Ancak proje sonucunda geliştirilmesi gereken bölümler bulunmaktadır. Örnek olarak bulut ile karıştırılabilecek olan kar ve su bölgeleri bulunmaktadır. Bu bölgeler üzerindeki bulutlu bölgelerin tespitinde model çok doğru sonuçlar verememektedir. İlerleyen çalışmalarda bu durumun göz önünde bulundurularak geliştirmeler yapılması tavsiye edilmektedir.

- [1] M. Segal-Rozenhaimer, A. Li, K. Das, and V. Chirayath, "Cloud detection algorithm for multi-modal satellite imagery using convolutional neural-networks (cnn)," *Remote Sensing of Environment*, vol. 237, p. 111446, 2020, ISSN: 0034-4257. DOI: <https://doi.org/10.1016/j.rse.2019.111446>. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0034425719304651>.
- [2] C. Li, J. Ma, P. Yang, and Z. Li, "Detection of cloud cover using dynamic thresholds and radiative transfer models from the polarization satellite image," *Journal of Quantitative Spectroscopy and Radiative Transfer*, vol. 222-223, pp. 196–214, 2019, ISSN: 0022-4073. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0022407318304254>.
- [3] C. Deng, Z. Li, W. Wang, S. Wang, L. Tang, and A. C. Bovik, "Cloud detection in satellite images based on natural scene statistics and gabor features," *IEEE Geoscience and Remote Sensing Letters*, vol. 16, no. 4, pp. 608–612, 2019.
- [4] R. Gupta, S. J. Nanda, and U. P. Shukla, "Cloud detection in satellite images using multi-objective social spider optimization," *Applied Soft Computing*, vol. 79, pp. 203–226, 2019, ISSN: 1568-4946. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1568494619301681>.
- [5] Sorour. "38-cloud: Cloud segmentation in satellite images." (2021), [Online]. Available: <https://www.kaggle.com/datasets/sorour/38cloud-cloud-segmentation-in-satellite-images> (visited on 06/17/2023).

BİRİNCİ ÜYE

İsim-Soyisim: Muhammed İsa GÜL
Doğum Tarihi ve Yeri: 25.04.2001, Kocaeli
E-mail: isa.gul@std.yildiz.edu.tr
Telefon: +905378247164

İKİNCİ ÜYE

İsim-Soyisim: Hakan ADİYAMAN
Doğum Tarihi ve Yeri: 20.11.1997, Diyarbakır
E-mail: hakan.adiyaman@std.yildiz.edu.tr
Telefon: +905343741913

Proje Sistem Bilgileri

Sistem ve Yazılım: Windows İşletim Sistemi, Python 3
Gerekli RAM: 16GB
Gerekli Disk: 30GB